

과제

12240970 노초환

12213039 박진하

1. 문제정의 및 데이터셋 특성

1.1. 문제정의

은행 산업에서 신규 고객 유치 비용은 기존 고객 유지 비용보다 훨씬 높습니다. 본 데이터셋의 신용 점수, 자산 규모, 활동성 등의 변수를 활용한 분류 모델은 고객의 이탈 징후를 선제적으로 포착할 수 있고, 이는 신규 고객 유치 비용 절감으로 이어집니다.

1.2. 데이터셋 구성 및 특성

분류	Features	Label
변수 명	CreditScore, Geography, Gender, Age, Tenure(거래 기간, Years), Balance(잔고), NumOfProducts, IsActiveMember, EstimatedSalary(€)	Churn (고객 이탈)
데이터 예시 1	619, France, Female, 42, 2, 0.00, 1, 1, 101348.88	1(이탈)
데이터 예시 2	608, Spain, Female, 41, 1, 83807.86, 1, 0, 112542.58	0(유지)

2. 어떤 알고리즘을 사용할 것인가? 그리고 다른 알고리즘을 선택하지 않은 이유(각각)

본 연구에서는 고객 이탈의 원인을 다각도로 분석하고 후속 대응 방안을 만들야 하는 필요성을 생각하여 Decision Tree를 최종 알고리즘으로 선정하였다. 선정 근거와 타 알고리즘의 부적합성은 다음과 같다.

2.1. 선정 알고리즘: Decision Tree

- 본 데이터셋은 약 10,000개의 충분한 샘플 수에 비해 독립 변수(Feature)의 개수가 9개로 적절히 제한되어 있다. 변수의 수가 과도하지 않으므로 트리가 기하급수적으로 복잡해지는 Deep Tree가 형성될 가능성이 상대적으로 낮다. 따라서 Decision Tree를 통해 데이터 간의 관계를 명확하고 직관적으로 모델링하기에 유리하다고 판단했다.

- 비선형적 관계 포착: 은행 고객 데이터는 특정 연령층(예: 은퇴 세대)이나 특정 자산 구간에서 이탈률이 급변하는 비선형적 특성을 보인다. Decision Tree는 데이터의 Threshold를 기준으로 영역을 분할하여 학습하는데, 이는 비선형적 특성을 지닌 데이터셋에 적합한 방식이다.

- 모델의 해석 가능성: 이탈 경로를 if-then 규칙으로 가시화할 수 있어, 어떤 이유에서 이러한 결과가 도출되는지 모르는 블랙박스 모델과 달리 즉각적으로 이해하고 전략에 반영할 수 있는 화이트박스 모델이다. 본 과제에 사용한 데이터셋은 분류보다 원인 분석이 필요한 데이터셋이라고 판단하여 Decision Tree의 특징이 잘 어울린다고 판단했다.

2.2. 타 알고리즘 제외 사유

- Linear Regression: 종속 변수인 이탈 여부(Churn)는 Discrete 범주 데이터이므로, 연속적인 수치를 예측하는 Linear Regression은 통계적 메커니즘상 적용이 불가능하다.

- Logistic Regression: 선형적 상관관계를 가정하므로 변수 간의 복잡한 상호작용(예: 특정 국가 내에서의 연령별 행동 차이 등)을 포착하는 데 한계가 있으며, Decision Tree 대비 직관적인 규칙 생성이 어렵다.

- Support Vector Machine: 고차원 분류 성능은 우수하나, 사용한 데이터셋이 Decision Tree 대신 SVM을 사용할 정도로 고차원 데이터셋이라고 판단하지 않았다. 게다가 커널 공간으로의 투영 과정에서 왜 이 고객이 이탈하는가에 대한 인과관계 해석이 불가능하므로 본 연구의 목적인 원인 분석에 부합하지 않는다.

3. 결과 추측 및 기대 통찰

본 과제에서는 제시된 데이터셋의 변수 분포와 의사결정나무의 수학적 메커니즘을 결합하여 다음과 같은 결과를 추측한다. 모든 분석은 모델 학습 전 데이터셋의 통계적 특성에 기반한 가설이다.

3.1. Entropy 감소를 통한 핵심 변수 추측

데이터셋의 레이블(Churn)이 0과 1로 혼재된 상태에서, 특정 변수로 분할했을 때의 Entropy 변화를 예측한다.

- 추측: Age와 IsActiveMember 변수가 Root Node 인근에서 분할 기준이 될 것으로 추측한다.
- 근거: 은행 산업 특성상 특정 연령대와 서비스 활동 여부는 고객의 상태를 가장 명확히 구분짓는 척도이다. 따라서 해당 변수들로 데이터를 분할했을 때 발생하는 Information Gain이 다른 변수들 보다 수학적으로 높을 것이라고 판단된다.

3.2. 고차원 분할에 따른 Overfitting 발생 가능성

데이터셋의 피처 개수와 샘플의 상관관계를 통해 모델의 학습 양상을 추측한다.

- 추측: 모델 학습 시 트리의 깊이가 깊어질수록 훈련 데이터에 대한 Overfitting이 발생할 것으로 추측한다.
- 근거: 10,000개의 샘플 내에는 자산 규모가 매우 크거나 거주 지역이 특이한 소수 집단이 존재한다. 의사결정나무는 이러한 소수 샘플의 무작위적인 노이즈까지 설명하기 위해 조건부 분할을 반복하며 불필요하게 복잡한 기하학적 경계를 형성할 가능성이 높다.

3.3. Reduced Error Pruning을 통한 일반화 오차 개선

Overfitting 문제를 수학적으로 해결하기 위한 후속 처리 결과에 대해 추측한다.

- 추측: Reduced Error Pruning를 적용했을 때, 모델의 전체적인 Normalization Accuracy가 향상될 것으로 추측한다.
- 근거: 앞서 언급한 소수 집단(예: 자산가 패턴)을 설명하기 위해 생성된 복잡한 가지들은 검증 데이터셋에서 오차를 유발할 확률이 높다. 해당 기법을 통해 전체 오차를 줄이지 못하는 하위 가지들을 수학적으로 제거함으로써, 모델이 보편적인 데이터 분포에 집중하게 되어 최종적인 판정 정확도가 최적화될 것이라고 기대한다.