

# 기계학습 Term Project 2

12240970 노초환 & 12213039 박진하

## 1. 프로젝트 방향 변경 이유 및 새로운 문제 정의

### 1-1. 기존 문제 정의의 한계와 신규 타겟 지표 정의

Term Project 1 당시 프로젝트는 최초 설계 당시 데이터셋에 내재된 churn 라벨을 종속 변수로 설정하여 이탈 여부를 예측하는 Binary Classification 프로젝트를 수행하고자 하였다. 그러나 이는 미리 정의된 문제를 수동적으로 적용하는 것에 그친다는 문제가 있었다. 이에 본 프로젝트는 기존 이탈 라벨(churn)을 폐기하고, 동일한 데이터의 특징 중 예측 대상으로 삼을 변수를 새로 선택하여 문제를 재정의하였다.

새롭게 정의한 문제는 고객의 프로필을 바탕으로 해당 고객이 고저축 고객일 가능성을 예측하는 것이다. 은행의 관점에서 계좌 잔고는 핵심적인 자금 조달원(은행의 부채)이므로, 어떤 고객이 자산을 많이 예치하는 성향을 갖는지 사전에 식별하는 일은 마케팅 관점으로 매우 중요하다. 구체적으로 전체 고객의 잔고의 중앙값을 임계값으로 하여, 잔고가 중앙값 이상인 고객을 고저축 고객( $y=1$ ), 중앙값 미만인 고객을 일반 고객( $y=0$ )으로 라벨링하였다. 중앙값을 기준으로 삼은 것은 "평균적 고객보다 많이 예치하는가"라는 직관적인 의미를 가지면서, 동시에 두 클래스의 표본 수를 각각 절반으로 균형 있게 유지하여 분류 성능을 편향 없이 평가하기 위함이다.

$$B_{med} = median(balance) \approx 97,198.5, y_i = 1[balance_i \geq B_{med}]$$

기술적인 포인트는 라벨 생성의 근거가 된 balance를 입력 변수에서 제외한다는 점이다. 만약 balance를 입력에 포함하면 정답이 입력 안에 그대로 들어 있게 되어, 모델은 예측이 아니라 라벨의 정의를 복원하는 trivial problem이 된다. 따라서 balance를 제외한 나머지 특징들(신용점수, 거주 국가, 성별, 나이, 거래 기간, 보유 상품 수, 카드 보유 여부, 활동성, 추정 연봉)만으로 고저축 여부를 예측하도록 설계함으로써, 실제 불확실성이 존재하는 유의미한 분류 문제로 재정의하였다.

### 1-2. Decision Tree 알고리즘 선정의 정당성 및 타 알고리즘과의 비교

본 문제는 범주형 변수(country, gender)와 수치형 변수(credit\_score, age, tenure 등)가 섞여있는 정형 데이터에 대한 이진 분류이다. 단순히 높은 정확도를 얻는 것을 넘어, "어떤 특성의 고객이 고저축 고객인가"를 사람이 이해할 수 있는 형태로 제시하는 것이 본 프로젝트의 목적이다.

모델을 적용하기에 앞서, 본 문제의 데이터 구성과 금융 도메인 특성으로부터 두 가지를 예상할 수 있다. 첫째, 변수 간 상호작용이 존재할 가능성이 높다. 고객의 저축 성향은 거주 국가의 금융 환경에 따라 다를 수 있고, 연령이나 거래 기간이 잔고에 미치는 영향 또한 집단별로 다르게 작용할 수 있다. 둘째, 일부 변수는 잔고와 단조적이지 않은 관계를 가질 수 있다. 예를 들어, 보유 상품 수가 많다고 해서 잔고가 반드시 비례하여 증가한다고 보기는 어렵다. 따라서 변수 간 조건부 상호작용과 급격하게 꺾이는 데이터 패턴을 정확하게 포착함과 동시에, 분류 근거를 규칙으로 제시할 수 있는 모델이 본 프로젝트에는 필요하다.

Decision Tree는 이 조건에 부합한다. 특징 공간을 임계값 기준으로 재귀적으로 분할하므로 구간별 및 비단조적 관계를 별도의 변환 없이 표현할 수 있다. 또한 상위 노드에서 한 변수로 분기한 뒤 하위에서 다른 변수로 다시 나누는 계층 구조 자체가 변수 간 상호작용을 자동으로 반영한다. 수치형 변수를 크기가 아닌 순서 및 임계값으로 다루어 스케일 정규화가 불필요하며, 가장 중요하게, 각 분기 경로가 그대로 If-Then 규칙이 되어 해석의 목적을 충족한다.

반면 다른 알고리즘은 위 요건과 구조적으로 어긋난다. 첫째, Logistic Regression은 각 특징에 가중치를 곱해 더한 선형 결합으로 분류하는 선형 모델이다. 즉 결정 경계가 직선 형태이고, 한 특징이 커질수록 결과가 일정한 크기로 한 방향으로만 변한다고 가정한다. 따라서 예상되는 비단조적 관계나 변수 간 상호작용을 반영하려면 우리가 구간화 및 상호작용항을 직접 설계해 넣어야 하며, 이는 모델이 스스로 발견해야 할 구조를 사람이 미리 알고 넣어야 한다. 둘째, SVM은 커널을 통해 비선형 경계는 그릴 수 있으나, 그 경계가 고차원 커널 공간에 형성되어 원래 특징 기준의 규칙으로 환원할 수 없다. 또한, 분류는 가능하되 그 근거를 제시하지 못하여 우리의 목적인 근거 기반 선별 목적과 어긋난다. 셋째, MLP는 비선형 함수를 근사할 수 있어 상호작용 및 비단조 관계 자체는 학습이 가능하다. 그러나 분류 근거를 규칙으로 제시할 수 없는 블랙박스 알고리즘이기에 배제했다.

## 2. 하이퍼파라미터 규제에 따른 모델 학습 결과 비교

본 구현에서는 파이썬 환경에서 pandas와 numpy로 전처리를 수행했고, scikit-learn의 DecisionTreeClassifier를 활용하여 모델 학습을 수행하였다. 전체 10,000개 샘플을 8:2 비율로 분할하되 두 클래스 비율이 학습 및 검증에서 동일하게 유지되도록 계층적인 분할을 적용하였으며, 재현성을 위하여 난수 시드를 고정하였다. 범주형 변수(country, gender)는 원-핫 인코딩하였고, 라벨 생성에 사용된 balance는 입력에서 제외하였다.

구조적 제약이 없는 트리(Model A)와 하이퍼파라미터의 규제(max\_depth=4, min\_samples\_split=10)를 적용한 규제 트리(Model B)를 구축하여 성능을 분석한 결과는 아래와 같다.

| 모델      | Training Accuracy | Test Accuracy | Gap    |
|---------|-------------------|---------------|--------|
| Model A | 1.0000            | 0.6085        | 0.3915 |
| Model B | 0.7216            | 0.7090        | 0.0126 |


Model A는 훈련 정확도가 1.0000으로 학습 데이터를 완벽히 분류하였으나, 테스트 정확도는 0.6085에 그쳐 둘 사이 격차가 0.39로 매우 커 overfitting 문제를 보였다. 제약이 없어 개별 샘플의 노이즈까지 분기로 학습한 결과, 새 데이터 예측력이 떨어진 것이다.

반면 Model B는 트리 깊이를 4단계로 제한하여 표현력을 통제하였다. 제약으로 인해 훈련 정확도는 0.7216으로 낮아졌으나(bias 증가), 테스트 정확도는 0.7090으로 상승하였고 두 정확도의 격차가 0.01 수준으로 거의 사라졌다. 이는 모델이 지엽적인 노이즈를 배제하고 데이터의 보편적 패턴만 학습하여 일반화 성능을 확보했다는 의미이다.

특히 본 문제의 라벨은 입력 특징만으로 결정되지 않는 실질적 불확실성을 지니므로, 여기서 관측된 Overfitting은 모델 복잡도에서 비롯된 실제 현상이며 규제를 통한 통제가 유효하게 적용되었다. Model B의 Confusion Matrix를 추출해보았을 때 [[665, 335], [247, 753]]로 고저축 고객(y=1)을 재현율: 0.75, F1-Score: 0.72로 식별하였다. 이에 일반화 성능이 우수한 Model B를 최종 모델로 선택했다.

### 3. Decision Tree의 시각화 및 단계별 Threshold 분석

최종 모델 B의 학습 결과로 도출된 의사결정나무의 형태는 아래와 같다. 참고로, 노드의 색상이 짙어질수록 불순도(gini)가 감소하는 것을 뜻하며(짙은 파란색(y=1)과 짙은 주황색(y=0)), 리프 노드로 갈수록 불순도가 점차 감소한다.



루트 노드는 country\_Germany <= 0.5를 기준으로 분기한다. 즉 모델은 고저축 여부를 가르는 가장 변별력 높은 단일 변수로 '독일 거주 여부'를 선택하였다. 독일 고객(2,012명)은 81%가 고저축 고객(value=[381, 1631])인 반면, 비독일(프랑스·스페인) 고객(5,988명)은 고저축 비율이 40%에 그친다(value=[3619, 2369]).

1차 분기 후, 비독일 고객은 2차로 products\_number 기준으로 갈린다. 상품 1개 보유 고객은 고저축 58%인 반면, 2개 이상 보유한 고객(3,007명)은 그 비율이 21%로 급감한다(value=[2377, 630]). 상품 수별로 보면 1->2개에서 떨어졌다가 3,4개에서 32%로 다시 오르는 비단조 관계여서, 단조 가정을 두는 선형 모델로는 포착하기 어렵다. 한편, 독일 고객에서 2차 분기를 할 때, age를 기준으로 분기를 하지만 두 연령 집단 모두 고저축이 우세하다. 즉 독일 고객은 연령과 무관하게 대부분 고저축으로 분류되어, 1차 분기(독일 출신 여부)만으로 이미 강한 결정력을 가진다. 더 깊은 단계에서는 estimated\_salary, age, credit\_score가 임계값으로 나타나 각 영역을 미세하게 조정한다. 특히 age는 독일과 비독일 양쪽 분기에 모두 나타나지만 그 영향의 방향이 집단마다 다르게 작용한다. 이는 Decision Tree가 특징 간 상호작용을 계층적 분기 구조로 발견한다고 볼 수 있다.

결론적으로, 분기된 구조는 다음과 같이 사람이 읽을 수 있는 규칙으로 요약된다. 첫째, 독일 고객이면 고저축으로 분류한다. 둘째, 비독일 고객이면 상품 2개 이상이면 저저축으로 분류한다. 셋째, 비독일인이면서, 상품 1개를 가입했고 43.5세 이하이면 고저축 경향이 높다. 이러한 규칙은 은행이 고저축 잠재 고객을 근거와 함께 선별하는 데 직접 활용될 수 있다.

### 4. 결론 및 기대효과

본 프로젝트는 은행 고객 데이터를 활용하여 고저축 고객 여부를 예측하는 이진 분류 문제를 설계하고, Decision Tree를 핵심 알고리즘으로 채택하여 모델을 구축하였다. Model A는 Overfitting을 보였지만, 규제를 적용한 Model B는 과적합을 억제하며 안정적인 일반화 성능을 확보하였다. 특히 모델이 도출한 분기 규칙인 독일 거주 여부, 보유 상품 수, 연령 순의 계층적 분기는 단순 선형 모델로는 포착하기 어려운 비단조적 패턴을 화이트박스 형태로 명시한다는 점에서, 예측 성능과 해석 가능성을 동시에 달성하였다.

기대효과 측면에서, 본 모델이 도출한 분기 규칙은 은행이 고저축 잠재 고객을 사전에 식별하여 예·적금 상품 가입 권유, 프리미엄 서비스 안내 등 타겟 마케팅 전략에 직접 활용할 수 있는 근거를 제공할 수 있다.